

테스트 계획 및 결과 보고서

개인 맞춤형 AI 문화유산 가이드

75,820	179,028
검증된 검색 문서	검색 청크
0.92	165 + 46
Hybrid Hit@3	자동 테스트·subtest 통과

실측 근거가 있는 데이터·검색·자동 테스트 결과와, 아직 공식 집계되지 않은 생성·Fine-tuning·E2E 항목을 구분해 작성했습니다.

SKN 33기 3차 프로젝트 · 1팀
기준일 2026-09-02 · main 69b964d

1. 요약

이 프로젝트는 한국민족문화대백과사전 원문을 검색하고, 검색 근거 안에서 설명 수준별 답변과 출처를 제공하는 RAG 서비스다. 데이터·검색·계약·UI를 단계별로 검증하고, 실제로 측정하지 않은 생성 품질이나 비용 수치는 결과로 기록하지 않았다.

평가 영역	핵심 결과	판정
원본 데이터	75,835건 검사, 정상 75,820건, 본문 누락 15건, 오류·중복 0건	PASS
전체 체크	75,820문서, 179,028체크, 누락·중복·필드 오류 0건	PASS
자동 테스트	Python 3.12.14에서 165개와 subtest 46개 통과	PASS
일반 검색 25문항	Hybrid Hit@3 0.92 , MRR 0.820	채택
고유명사 회귀 5문항	Hybrid Hit@1·Hit@3 1.00	PASS
생성 품질 전체 집계	수준별 생성·계약·RAGAS 기능은 구현, 공식 전체 평균은 미측정	제한사항
Fine-tuning	동일 조건의 전후 비교를 수행하지 않음	후속 과제
LangGraph	개선 가능성을 확인했으나 지연시간과 통합 일정 때문에 최종 경로에서 제외	후속 과제

2. 테스트 목적과 원칙

2.1 목적

- 수집 원본과 검색 청크가 누락·중복 없이 연결되는지 확인한다.
- Dense, BM25, Hybrid 중 현재 질문 세트에서 더 적절한 검색 방식을 찾는다.
- 검색 결과와 생성 결과의 실패 원인을 구분한다.
- LLM이 검색하지 않은 청크나 출처를 만들어 내지 못하게 계약을 검증한다.
- 근거 부족·모호한 질문·위험한 요청·범위 밖 질문을 구분해 처리한다.
- 개선 기법은 같은 질문과 조건으로 비교하며 한 번에 하나의 요소만 바꾼다.

2.2 결과 기록 원칙

- **PASS**: 실제 검증 결과와 재현 근거가 있는 항목
- **PARTIAL**: 기능 또는 기준은 있으나 공식 전체 평가가 끝나지 않은 항목
- **NOT RUN**: 이번 프로젝트에서 실행하지 않은 항목
- **REFERENCE**: 조건 일부가 저장소에 없어서 참고용으로만 사용하는 결과

Mock 화면, 단위 테스트의 가짜 응답과 실제 API 실행 결과를 같은 결과로 합치지 않는다.

3. 테스트 환경

항목	값
자동 테스트 실행일	2026-09-02
자동 테스트 commit	69b964d372aa4d27ba524e2eb517dfb37724d11f
CI 환경	GitHub Actions, Ubuntu 24.04.4, Python 3.12.14
원본 데이터	AKS 상세 API JSON 75,835건
검색 corpus	75,820문서, 179,028청크
청킹 기준	최대 1,500자, overlap 200자, definition-body 분리
Embedding	text-embedding-3-small , 1,536차원, cosine
Vector DB	Pinecone aks-rag-v1 , __default__ namespace
BM25	SQLite FTS5, 제목·별칭·본문 색인
Hybrid	후보 10/10, RRF k=60 , 가중치 1.5/1.0
최종 검색 결과	top_k=3 , 문서당 최대 2청크, RRF threshold 없음
생성	RunPod Ollama, exaone3.5:7.8b-instruct-q8_0
생성 설정	temperature 0.0 , think=false , JSON Schema
Prompt	prompt-baseline-v0-ollama

자동 테스트는 외부 API를 실제 호출하는 성능 시험이 아니라, Mock과 test double을 사용한 코드·계약 회귀 검사다. 실제 검색 성능은 별도의 Dense-BM25-Hybrid 평가 실행 결과를 사용한다.

4. 평가 데이터

평가 세트	문항 수	구성	검토 상태	사용 목적
RAG Dev v1	48	answered 20, insufficient 8, clarification 5, corrected 5, safety 5, out-of-scope 5	approved 40, draft 8	반복 개발·응답 유형 평가
검색 평가 대상	25	Dev의 answered 20 + corrected 5	Dev 상태를 따름	Dense-BM25-Hybrid 공식 비교
Holdout v1	12	여섯 응답 유형 각 2건	draft 12	최종 후보의 마지막 검증
고유명사 회귀 v1	5	경복궁·석굴암·종묘·향원정·백제금동대향로	draft 5	정확한 표제어 검색 회귀
초기 Retrieval v1	20	서로 다른 분야 각 1건	별도 review 필드 없음	초기 Dense 기준 확인

draft 문항은 평가 재료로 사용할 수 있지만 사람 검수가 끝난 공식 Holdout으로 보지는 않는다. Holdout 결과를 반복해 보면서 설정을 조정하지 않는다.

5. 평가 방법

5.1 데이터 품질

- JSON 파싱 성공 여부
- EID 중복·누락
- 본문 유무와 corpus 제외 처리
- manifest 대상 문서와 청크 문서의 완전 일치
- 필수 필드와 자료형
- 청크 ID 중복과 빈 content
- 파일 경로·크기·SHA-256 기록

5.2 검색

- **Hit@1**: 기대 문서가 첫 번째 결과인지 확인한다.
- **Hit@3**: 기대 문서가 상위 3개 안에 있는지 확인한다.
- **MRR**: 정답 문서가 앞에 있을수록 높은 점수를 준다.
- 평균 검색 시간: 질문 1건의 검색과 결합에 걸린 평균 시간이다.

이번 비교의 정답은 **document_id**를 기준으로 판정한다. 같은 문서의 definition·body 청크 중 어느 것이 검색되든 문서 적중으로 계산한다.

5.3 생성·RAG 답변

- 자동 검사: JSON 구조, 필수 필드, 응답 유형, **used_chunk_ids** 유효성
- 정상 답변 평가: 근거 일치 40점, 질문 충족 25점, 설명 수준 25점, 명확성 10점
- 보류·거절 평가: 기대 응답 유형, 빈 청크 ID 목록, 추측 여부를 PASS/FAIL로 확인
- RAGAS: 개별 답변의 Faithfulness와 Answer Relevancy를 계산하도록 구현
- 사람 검토: 자동 검사와 LLM 평가가 충돌하거나 실패한 사례를 우선 확인

근거 일치 또는 질문 충족이 0점이면 총점과 관계없이 실패다. 글자 수 이탈은 초기에는 실패가 아닌 **length_warning**으로 기록한다.

6. 테스트 계획과 수행 상태

ID	영역	계획	결과 근거	상태
DATA-01	원본	75,835건의 형식-EID·본문·중복 검사	outputs/aks_raw_validation.*	PASS
DATA-02	체크	manifest와 전체 체크의 문서·필드-ID 검사	Document Card와 체크 검증 기록	PASS
RET-01	Dense	Dev 25문항 Hit@1·Hit@3·MRR-시간	Hybrid 검색 보고서	PASS
RET-02	BM25	같은 질문·top-k로 단독 비교	Hybrid 검색 보고서	PASS
RET-03	Hybrid	RRF 결합과 문서당 제한 적용 비교	Hybrid 검색 보고서	PASS
RET-04	고유명사	이름이 직접 포함된 5문항 회귀	고유명사 회귀 보고서	PASS
GEN-01	출력 계약	JSON Schema와 여섯 응답 유형 검사	pytest	PASS
GEN-02	출처	검색에 없는 ID 차단·Citation 조립	pytest	PASS
GEN-03	수준별 답변	easy/general/advanced Prompt와 길이 설정	코드·표본 확인	PARTIAL
SAFE-01	안전	비밀정보 요청을 검색 전에 거절	pytest	PASS
SAFE-02	범위	실시간·코딩 등 범위 밖 요청 차단	pytest	PASS
UI-01	화면	실제/Mock 모드, 출처 묶기, 근거 보기	pytest·시연 확인	PASS
UI-02	접근	빈 질문 안내와 브라우저 TTS	pytest·시연 확인	PASS
EVAL-01	RAGAS	개별 응답 Faithfulness-Relevancy 계산	구현·pytest	PARTIAL
E2E-01	통합	질문부터 답변·출처까지 성공률·P95	공식 집계 없음	NOT RUN
FT-01	Fine-tuning	같은 기반 모델의 전후 품질 비교	학습 미실행	NOT RUN

7. 수행 결과

7.1 원본과 청크 품질

항목	결과	판정
상세 원본 JSON	75,835건	PASS
정상 corpus 대상	75,820건	PASS
본문 누락	15건, corpus 제외	PASS
JSON 파싱 오류	0건	PASS
중복 EID	0건	PASS
JSONL 누락 EID	0건	PASS
최종 청크	179,028건	PASS
manifest 대상 문서 누락	0건	PASS
제외 문서의 잘못된 포함	0건	PASS
빈 청크·중복 청크 ID·필드 오류	0건	PASS

대용량 청크 검증 JSON은 최종 제출 파일을 기준으로 다시 생성하여 파일 크기·SHA-256·검사 시각을 확정해야 한다.

7.2 자동 테스트

항목	결과
Workflow	Python tests
실행 환경	Ubuntu 24.04.4, Python 3.12.14
결과	165 passed, 46 subtests passed
실행 시간	1.68초
판정	PASS

자동 테스트는 데이터 수집 로직, 청킹, Pinecone Adapter, BM25-Hybrid 결합, RAG 계약, 안전·범위 검사, Ollama 구조화 출력, Streamlit 연결과 RAGAS 평가 연결을 검사한다.

7.3 Dense·BM25·Hybrid 비교

Dev의 검색 평가 대상 25문항을 동일한 **top_k=3**으로 비교했다.

검색 방식	Hit@1	Hit@3	MRR	평균 검색 시간
Dense	0.76 (19/25)	0.88 (22/25)	0.800	0.601초
BM25	0.20 (5/25)	0.32 (8/25)	0.260	0.442초
Hybrid	0.76 (19/25)	0.92 (23/25)	0.820	1.043초

Hybrid는 Dense보다 정답 문서를 상위 3개 안에서 한 건 더 찾았고 MRR도 **0.020** 높았다. 대신 평균 검색 시간은 **0.442초** 늘었다. BM25 단독 성능은 낮아 Dense를 대체하지 않고 정확한 제목·별칭을 보완하는 용도로 사용한다.

7.4 고유명사 회귀

방식	Hit@1	Hit@3	MRR
Dense	0.60 (3/5)	0.80 (4/5)	0.667
BM25	1.00 (5/5)	1.00 (5/5)	1.000
Hybrid	1.00 (5/5)	1.00 (5/5)	1.000

Dense는 **중요** 질문에서 **중앙중요(중요)**를 먼저 찾고, **항원정** 질문에서 **항원사**를 먼저 찾는 사례가 있었다. 제목·별칭 일치를 사용하는 Hybrid는 두 질문 모두 기대 원문을 1위로 복원했다.

7.5 검색 설정 비교

비교 항목	확인 결과	채택 기준
후보 수 5/10/20/25	후보가 많다고 항상 좋아지지 않음	Dense 10 + BM25 10
최종 top-k 3/5	5개로 늘려도 놓친 두 질문을 추가로 찾지 못함	top_k=3
문서당 제한 없음/2/1	최대 2개는 Hit 지표를 유지하며 한 문서 3개 독점 방지	최대 2개
Dense 가중치 1.0~2.5	1.5 이상은 동일 성능, 1.0은 하락	Dense 1.5 / BM25 1.0
RRF threshold	정답·오답·범위 밖 점수 분포가 크게 겹침	적용하지 않음

7.6 생성·답변 품질

다음 기능은 구현과 자동 검사가 완료됐다.

- EXAONE 3.5 기반 Ollama 생성
- easy/general/advanced 수준별 Prompt와 생성량
- 여섯 응답 유형의 구조화 출력
- 검색 결과에 존재하는 **used_chunk_ids**만 허용
- 사용된 청크에서 Citation과 근거 문장을 복사
- 개별 답변의 RAGAS Faithfulness-Answer Relevancy 계산

그러나 전체 Dev-Holdout을 실제 생성 모델로 실행한 평균 점수, 환각률, 응답 유형 정확도, 평균·P95 응답시간과 비용은 공식 집계되지 않았다. 따라서 화면의 개별 평가값이나 예시 응답을 전체 모델 성능으로 해석하지 않는다.

Qwen과 EXAONE 답변을 사람이 비교한 표본에서는 EXAONE이 어려운 한자어를 줄이고 연도 흐름을 풀어 설명하는 경향이 관찰되어 시연 모델로 선택했다. 동일 고정 문맥·동일 Prompt의 정량 비교가 아니므로 공식 모델 순위로 단정하지 않는다.

7.7 LangGraph 참고 실험

발표자료에 정리된 같은 질문 세트 비교 결과는 다음과 같다.

지표	기존 방식	초기 LangGraph	이유 기반 LangGraph
응답 유형 정확도	72.7%	69.7%	78.8%
보류 판단 정확도	72.7%	69.7%	84.8%
Citation precision	100.0%	100.0%	95.0%
Citation recall	64.0%	60.0%	76.0%
평균 응답시간	7,628ms	7,936ms	9,725ms
재검색 문항	0건	18건	0건
실행 오류	0건	0건	0건

초기 LangGraph는 정확도가 낮아지고 불필요한 재검색이 늘었다. 이유 기반 분기는 정확도와 Citation recall을 높였지만 기존 방식보다 평균 응답시간이 약 2.1초 늘고 Citation precision이 5%p 낮아졌다.

이 결과의 평가 문항 수, commit, Prompt·모델 설정과 원본 결과 파일이 현재 저장소에 완전하게 남아 있지 않으므로 **REFERENCE**로 분류한다. 일정 안에 최종 서비스와 통합 회귀 검증을 마치기 어려워 3차 프로젝트 실행 경로에는 포함하지 않았다.

8. 대표 실패 사례

사례	증상	구분	현재 대응	후속 개선
종묘	Dense 1위가 중앙종묘 (ㄸ)	검색 실패	Hybrid에서 원문 1위	회귀 세트 유지
향원정	Dense 1위가 향원사	검색 실패	Hybrid에서 원문 1위	제목·별칭 평가 확대
Dev 006-015	세 검색 방식 모두 top-3 미적중	검색 실패	실패 사례로 보존	Query rewrite-reranker 검토
직지	사용자가 기대한 표제어 대신 유사한 다른 항목 노출 가능	표제어·오타 처리 부족	공식 정량 결과 없음	exact title-alias 후보 안내 연결
복합 질문	여러 질문을 하나의 검색으로 처리하면 일부 근거 누락	요청 처리 한계	한 번에 한 질문을 요청	질문 분해·질문별 검색 검토
근거 부족	점수만으로 답변 가능 여부를 구분하기 어려움	근거 판정 한계	threshold 없이 내용 확인	의미 기반 EvidenceChecker 비교

9. 과제에서 제시한 평가 방법 적용 여부

제시된 평가 기술을 모두 사용해야 하는 것은 아니며, 실제 구현 대상과 실행 결과가 있는 항목만 결과로 포함했다.

평가 방법	3차 프로젝트 적용	설명
데이터셋 품질	적용	결측·중복·누락·필드·출처 추적 검사
Embedding-Retriever	적용	Dense-BM25-Hybrid Hit@1·Hit@3-MRR-시간 비교
Hybrid Search	적용	RRF 설정과 고유명사 회귀 검증
RAG 답변·환각	부분 적용	RAGAS와 Citation 검증 구현, 공식 전체 집계 미완료
LLM-as-a-Judge	부분 적용	RAGAS 평가 연결, 전체 모델 비교 결과 미완료
Human Evaluation	표본 관찰	Qwen-EXAONE 응답을 비교했으나 공식 점수표는 미완료
시스템 통합	부분 적용	실제 시연 흐름과 자동 테스트 완료, E2E 성공률·P95 미측정
LangGraph	참고 실험	개선 가능성 확인, 최종 서비스 미통합
Fine-tuning-LoRA-QLoRA	미적용	동일 조건의 학습 전후 비교 미수행
BLEU-ROUGE-Exact Match/F1	미적용	서술형 답변의 공식 기준 답안·전체 실행 결과 미완료
Reranker-GraphRAG-Agent	미적용	이번 MVP 범위 밖
LangSmith Trace	미적용	화면의 자체 실행 과정 표시를 사용

10. 결론과 제한사항

10.1 채택한 구성

Dense 후보 10 + BM25 후보 10
 → RRF(k=60, 1.5/1.0)
 → 문서당 최대 2청크
 → 최종 top_k=3
 → 점수 threshold 없이 근거 내용 확인
 → EXAONE 3.5 수준별 답변
 → used_chunk_ids 검증 후 Citation 조립

Hybrid는 일반 Dev에서 Hit@3와 MRR을 개선했고, 고유명사 회귀에서 Dense의 대표 실패를 보완했다. 증가한 검색 시간은 평균 약 0.44초로, 고유명사 검색 안정성 개선과 교환되는 비용이다.

10.2 남은 제한

- Holdout 12건과 고유명사 회귀 5건의 사람 검수 상태가 **draft**다.
- 생성 품질·환각률·응답 유형 정확도의 전체 집계가 없다.
- 전체 E2E 성공률과 평균·P95 응답시간, 호출 비용을 측정하지 않았다.
- Fine-tuning 전후 비교를 수행하지 않았다.
- 청킹 후보 CH-01~04의 공식 검색·답변 품질 비교가 끝나지 않았다.
- LangGraph 개선안은 조건 기록과 통합 회귀 검증이 부족해 최종 서비스에서 제외했다.

10.3 후속 우선순위

1. Holdout과 회귀 문항의 사람 검수를 완료한다.
2. 실제 서비스 경로로 Dev-Holdout을 실행해 응답 유형, Citation, 지연시간을 집계한다.
3. 의미 기반 EvidenceChecker 또는 reranker를 비교한다.
4. 오타·별칭 후보 안내와 복합 질문 분해를 각각 별도 기능으로 검증한다.
5. LangGraph 개선안을 같은 환경에서 다시 측정한 뒤 정확도와 지연시간을 함께 판단한다.
6. Fine-tuning은 고정 문맥·같은 기반 모델·같은 Prompt 기준선을 확보한 뒤 진행한다.

11. 재현 명령

```
# 전체 자동 테스트
python -m pytest -q

# Dense-BM25-Hybrid 비교
python scripts/evaluate_hybrid_retrieval.py `
--cases data/evaluation/aks_rag_dev_v1.jsonl `
--split dev --top-k 3

# 고유명사 회귀
python scripts/evaluate_hybrid_retrieval.py `
--cases data/evaluation/aks_named_heritage_regression_v1.jsonl `
--split regression --top-k 3 `
--output outputs/aks_named_heritage_regression_result.json

# 전체 청크 무결성 재검증
python scripts/validate_aks_chunks.py `
--input data/processed/aks_full_chunks.jsonl `
--manifest data/manifest.csv `
--report outputs/aks_full_chunks_validation.json
```

실제 검색 명령은 OpenAI와 Pinecone 키, BM25 DB가 필요하다. 실제 답변 생성에는 접근 가능한 Ollama HTTP Service가 추가로 필요하다.

12. 근거 문서

- `outputs/aks_raw_validation.json`, `outputs/aks_raw_validation_report.md`
- `docs/document-card.md`
- `docs/hybrid_retrieval_evaluation_report.md`
- `docs/hybrid_retrieval_experiment_matrix.md`
- `docs/named_heritage_retrieval_regression_report.md`
- `docs/track_b/02_generation_contract.md`
- `docs/track_b/03_prompt_baseline.md`
- `docs/track_b/04_generation_evaluation_criteria.md`
- GitHub Actions run **33585427145**
- 3차프로젝트_공유용_수정본.pptx의 검색·LangGraph·모델 비교 슬라이드